

TP2 - Franco Marcelo Morero

June 8, 2026



Universidad de Buenos Aires Laboratorio de Sistemas Embebidos Especialización en Inteligencia Artificial

Probabilidad y Estadística para la Inteligencia Artificial

Docente: Camilo Argoty

Nombre: Franco Marcelo Morero

Código: a2533

Fecha: 8 de Junio de 2026

SEGUNDO EXAMEN PARCIAL

1. (3 puntos) Una variable aleatoria discreta X puede tomar los valores 0, 1, 2 y 3. Las probabilidades para cada valor posible están dadas por la siguiente tabla:

X	0	1	2	3
p	$\frac{2\theta}{3}$	$\frac{4\theta}{3}$	$\frac{1-2\theta}{3}$	$\frac{2(1-2\theta)}{3}$

Si experimentalmente se obtienen los siguientes datos:

$(2, 0, 2, 2, 1, 0, 0, 3, 0, 3),$

determine el valor de θ usando el método de máxima verosimilitud.

La variable aleatoria X toma los valores 0, 1, 2, 3 con probabilidades:

$$P(X=0) = \frac{2\theta}{3} \quad P(X=2) = \frac{1-2\theta}{3}$$

$$P(X = 1) = \frac{4\theta}{3} \quad P(X = 3) = \frac{2(1 - 2\theta)}{3}$$

Tenemos los datos $(2, 0, 2, 2, 1, 0, 0, 3, 0, 3)$, con $n = 10$.

Contamos cuántas veces aparece cada valor:

$$\#(0) = 4 \quad \#(1) = 1 \quad \#(2) = 3 \quad \#(3) = 2$$

Como las observaciones x_i son independientes, la función de verosimilitud es el producto de las probabilidades:

$$L(\theta) = \prod_{i=1}^n P(X = x_i) = [P(X = 0)]^4 [P(X = 1)]^1 [P(X = 2)]^3 [P(X = 3)]^2$$

Reemplazando:

$$L(\theta) = \left(\frac{2\theta}{3}\right)^4 \left(\frac{4\theta}{3}\right)^1 \left(\frac{1-2\theta}{3}\right)^3 \left(\frac{2(1-2\theta)}{3}\right)^2$$

Agrupando potencias de 2, de 3 y los factores en θ :

$$L(\theta) = \frac{2^4}{3^4} \cdot \frac{2^2}{3} \cdot \frac{1}{3^3} \cdot \frac{2^2}{3^2} \theta^4 \theta (1 - 2\theta)^3 (1 - 2\theta)^2$$

$$L(\theta) = \frac{2^8}{3^{10}} \theta^5 (1 - 2\theta)^5$$

Aplicamos logaritmo natural para trabajar con la log-verosimilitud. Recordando que el logaritmo de un producto es la suma de logaritmos y que $\ln(a^k) = k \ln(a)$:

$$\begin{aligned} \ell(\theta) &= \ln(L(\theta)) = \ln \left[\frac{2^8}{3^{10}} \theta^5 (1 - 2\theta)^5 \right] \\ &= \ln \left(\frac{2^8}{3^{10}} \right) + \ln(\theta^5) + \ln[(1 - 2\theta)^5] \\ &= \ln \left(\frac{2^8}{3^{10}} \right) + 5 \ln(\theta) + 5 \ln(1 - 2\theta) \end{aligned}$$

Derivamos respecto de θ .

- El primer término es constante (su derivada es 0).
- Para el segundo, $\frac{d}{d\theta} 5 \ln(\theta) = \frac{5}{\theta}$.
- Para el tercero aplicamos la regla de la cadena sobre $\ln(1 - 2\theta)$, cuya derivada interna es -2 :

$$\frac{d}{d\theta} 5 \ln(1 - 2\theta) = 5 \cdot \frac{1}{1 - 2\theta} \cdot (-2) = -\frac{10}{1 - 2\theta}$$

Entonces la derivada de la log-verosimilitud, igualada a cero:

$$\frac{d\ell}{d\theta} = \frac{5}{\theta} - \frac{10}{1 - 2\theta} = 0$$

Resolviendo:

$$\frac{5}{\theta} = \frac{10}{1 - 2\theta}$$

$$5(1 - 2\theta) = 10\theta$$

$$5 - 10\theta = 10\theta \Rightarrow 5 = 20\theta \Rightarrow \hat{\theta} = \frac{1}{4}$$

Para confirmar que este punto crítico es un máximo (y no un mínimo o punto de inflexión), calculamos la segunda derivada de la log-verosimilitud:

$$\frac{d^2\ell}{d\theta^2} = -\frac{5}{\theta^2} - \frac{20}{(1 - 2\theta)^2}$$

El dominio válido de θ se obtiene exigiendo que las cuatro probabilidades sean mayores o iguales a cero:

$$\frac{2\theta}{3} \geq 0 \Rightarrow \theta \geq 0 \qquad \frac{4\theta}{3} \geq 0 \Rightarrow \theta \geq 0$$

$$\frac{1 - 2\theta}{3} \geq 0 \Rightarrow \theta \leq \frac{1}{2} \qquad \frac{2(1 - 2\theta)}{3} \geq 0 \Rightarrow \theta \leq \frac{1}{2}$$

Las cuatro reducen a dos restricciones activas: $\theta \geq 0$ y $\theta \leq \frac{1}{2}$, por lo tanto $\theta \in [0, \frac{1}{2}]$. En el interior del espacio paramétrico, $\theta \in (0, \frac{1}{2})$, la segunda derivada está definida y es estrictamente negativa, ya que ambos términos $-\frac{5}{\theta^2}$ y $-\frac{20}{(1 - 2\theta)^2}$ son negativos. Esto confirma que $\ell(\theta)$ es estrictamente cóncava y el punto crítico es un máximo global.

Por último, verificamos que el máximo está en el interior y no en los extremos. Para esta muestra particular,

$$L(0) = L(\frac{1}{2}) = 0,$$

mientras que en $\theta = \frac{1}{4}$ la verosimilitud es positiva. Por eso el máximo está en el interior del intervalo.

Como $\frac{1}{4} \in \left[0, \frac{1}{2}\right]$, el estimador de máxima verosimilitud es válido:

$$\hat{\theta} = \frac{1}{4}$$

1) X v.z. tome valores $0, 1, 2, 3$

$$P(X=0) = \frac{2\phi}{3} \quad P(X=2) = \frac{1-2\phi}{3}$$

$$P(X=1) = \frac{4\phi}{3} \quad P(X=3) = \frac{2(1-2\phi)}{3}$$

Datos: $(2, 0, 2, 2, 1, 0, 0, 3, 0, 3) \rightarrow n=10$

Vemos que en bi. de bi:

$$\#(0) = 4 \quad \#(2) = 3$$

$$\#(1) = 1 \quad \#(3) = 2$$

Ahora:

$$L(\phi) = \prod_{i=1}^n P(X=x_i)$$

$$= [P(X=0)]^4 \cdot [P(X=1)]^1 \cdot [P(X=2)]^3 \cdot [P(X=3)]^2$$

Como son independientes los x_i , los multiplicamos

$$L(\phi) = \left(\frac{2\phi}{3}\right)^4 \cdot \left(\frac{4\phi}{3}\right) \cdot \left(\frac{1-2\phi}{3}\right)^3 \cdot \left[\frac{2(1-2\phi)}{3}\right]^2$$

$$= \frac{2^4}{3^4} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2^2}{3^2} \cdot \phi^4 \cdot \phi \cdot (1-2\phi)^3 \cdot (1-2\phi)^2$$

$$= \frac{2^8}{3^{10}} \phi^5 (1-2\phi)^5$$

Aplicamos $\ln$

$$l(\phi) = \ln(L(\phi)) =$$

$$= \ln\left[\frac{2^8}{3^{10}} \phi^5 (1-2\phi)^5\right]$$

$$= \ln\left(\frac{2^8}{3^{10}}\right) + \ln(\phi^5) + \ln[(1-2\phi)^5]$$

$$= \ln\left(\frac{2^8}{3^{10}}\right) + 5\ln(\phi) + 5\ln(1-2\phi)$$

Derivamos e igualamos a 0

$$\frac{d}{d\phi} l(\phi) = \frac{d}{d\phi} \left[\ln\left(\frac{2^8}{3^{10}}\right) + 5\ln(\phi) + 5\ln(1-2\phi) \right] = 0$$

$$\frac{5}{\phi} - \frac{10}{1-2\phi} = 0$$

$$\frac{5}{\phi} = \frac{10}{1-2\phi}$$

$$5 \cdot (1-2\phi) = 10\phi$$

$$5 - 10\phi = 10\phi$$

$$5 = 20\phi$$

$$\phi = \frac{5}{20}$$

$$\boxed{\phi = \frac{1}{4}}$$

2. (3 puntos) Se pretende estimar los valores de producción Y (en miles de toneladas) de cierto material, en función del tiempo transcurrido X (en meses) usando los valores de la tabla:

X	Y
4	8
7	30
12	189
17	217
22	438

Se plantea un modelo de la forma $Y = a + bx + cx^2$. Encontrar los estimadores de mínimos cuadrados para a , b y c en este modelo.

Planteamos el modelo cuadrático. El valor ajustado para cada observación es:

$$\hat{y}_i = a + b x_i + c x_i^2$$

Los errores (residuos) son:

$$e_i = y_i - \hat{y}_i$$

Por mínimos cuadrados buscamos a , b y c que minimicen la suma de los errores al cuadrado:

$$h(a, b, c) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - a - b x_i - c x_i^2)^2$$

Derivamos $h(a, b, c)$ respecto de cada parámetro e igualamos a cero.

Respecto de a :

$$\frac{\partial h}{\partial a} = -2 \sum_{i=1}^n (y_i - a - b x_i - c x_i^2) = 0$$

$$\sum_{i=1}^n y_i - n a - b \sum_{i=1}^n x_i - c \sum_{i=1}^n x_i^2 = 0$$

$$\boxed{\sum_{i=1}^n y_i = n a + b \sum_{i=1}^n x_i + c \sum_{i=1}^n x_i^2}$$

Respecto de b :

$$\frac{\partial h}{\partial b} = -2 \sum_{i=1}^n x_i (y_i - a - b x_i - c x_i^2) = 0$$

$$\sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i - b \sum_{i=1}^n x_i^2 - c \sum_{i=1}^n x_i^3 = 0$$

$$\sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 + c \sum_{i=1}^n x_i^3$$

Respecto de c :

$$\frac{\partial h}{\partial c} = -2 \sum_{i=1}^n x_i^2 (y_i - a - b x_i - c x_i^2) = 0$$

$$\sum_{i=1}^n x_i^2 y_i - a \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i^3 - c \sum_{i=1}^n x_i^4 = 0$$

$$\sum_{i=1}^n x_i^2 y_i = a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i^3 + c \sum_{i=1}^n x_i^4$$

Estas tres ecuaciones normales forman un sistema lineal en a , b y c :

$$\begin{pmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{pmatrix}$$

Resolvemos el sistema con los datos de la tabla.

```
[12]: import numpy as np

x = np.array([4, 7, 12, 17, 22], dtype=float)
y = np.array([8, 30, 189, 217, 438], dtype=float)

n = len(x)

sum_y = np.sum(y)
sum_x = np.sum(x)
sum_x2 = np.sum(x**2)
sum_x3 = np.sum(x**3)
sum_x4 = np.sum(x**4)
sum_xy = np.sum(x * y)
sum_x2y = np.sum((x**2) * y)

A = np.array([
    [n,      sum_x,  sum_x2],
    [sum_x,  sum_x2, sum_x3],
    [sum_x2, sum_x3, sum_x4]
], dtype=float)
```

```

B = np.array([
    sum_y,
    sum_xy,
    sum_x2y
], dtype=float)

a, b, c = np.linalg.solve(A, B)

print("Sumatorias:")
print(f"n = {n}")
print(f"Sum y = {sum_y}")
print(f"Sum x = {sum_x}")
print(f"Sum x2 = {sum_x2}")
print(f"Sum x3 = {sum_x3}")
print(f"Sum x4 = {sum_x4}")
print(f"Sum xy = {sum_xy}")
print(f"Sum x2y = {sum_x2y}")

print("\nSistema:")
print(f"A =\n{A}")
print(f"B =\n{B}")

print("\nCoeficientes:")
print(f"a = {a}")
print(f"b = {b}")
print(f"c = {c}")

print("\nModelo final:")
print(f"y = {a:.4f} + {b:.4f}x + {c:.4f}x^2")

```

Sumatorias:

```

n = 5
Sum y = 882.0
Sum x = 62.0
Sum x2 = 982.0
Sum x3 = 17696.0
Sum x4 = 341170.0
Sum xy = 15835.0
Sum x2y = 303519.0

```

Sistema:

```

A =
[[5.0000e+00 6.2000e+01 9.8200e+02]
 [6.2000e+01 9.8200e+02 1.7696e+04]
 [9.8200e+02 1.7696e+04 3.4117e+05]]
B =
[ 882. 15835. 303519.]

```

Coeficientes:

a = -28.30487943998003

b = 6.316465301184136

c = 0.6434863019617959

Modelo final:

y = -28.3049 + 6.3165x + 0.6435x²

De la salida del código vemos que las sumatorias calculadas reproducen el sistema numérico planteado:

$$\begin{pmatrix} 5 & 62 & 982 \\ 62 & 982 & 17696 \\ 982 & 17696 & 341170 \end{pmatrix} \begin{pmatrix} \hat{a} \\ \hat{b} \\ \hat{c} \end{pmatrix} = \begin{pmatrix} 882 \\ 15835 \\ 303519 \end{pmatrix}$$

y al resolverlo obtenemos los estimadores de mínimos cuadrados $\hat{a}$, $\hat{b}$ y $\hat{c}$:

$$\hat{a} \approx -28.3049 \quad \hat{b} \approx 6.3165 \quad \hat{c} \approx 0.6435$$

Por lo tanto, el modelo ajustado nos queda:


$$\hat{y} = -28.3049 + 6.3165x + 0.6435x^2$$

Graficamos los puntos observados junto con la curva de mínimos cuadrados ajustada:

```
[13]: import matplotlib.pyplot as plt

# Curva ajustada y = a + b x + c x^2 sobre un rango continuo de x
x_curva = np.linspace(x.min(), x.max(), 200)
y_curva = a + b * x_curva + c * x_curva**2

plt.figure(figsize=(8, 5))
plt.scatter(x, y, color="red", zorder=3, label="Datos observados")
plt.plot(x_curva, y_curva, color="blue",
         label=fr"Ajuste: $y = \{a:.2f\} + \{b:.2f\}x + \{c:.2f\}x^2$")
plt.xlabel("X (meses)")
plt.ylabel("Y (miles de toneladas)")
plt.title("Ajuste por mínimos cuadrados")
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```



$$2) \hat{y} = a + bx + cx^2$$

los errores son:

$$e_i = y_i - \hat{y}_i$$

Entonces por mínimos cuadrados queremos encontrar a, b y c que minimicen:

$$h(a, b, c) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ = \sum_{i=1}^n (y_i - a - bx_i - cx_i^2)^2$$

Derivamos:

$$\frac{\partial h}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i - cx_i^2) = 0 \\ \sum_{i=1}^n y_i - na - b \sum_{i=1}^n x_i - c \sum_{i=1}^n x_i^2 = 0$$

$$\sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i + c \sum_{i=1}^n x_i^2$$

$$\frac{\partial h}{\partial b} = -2 \sum_{i=1}^n x_i (y_i - a - bx_i - cx_i^2) = 0$$

$$\sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i - b \sum_{i=1}^n x_i^2 - c \sum_{i=1}^n x_i^3 = 0$$

$$\sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 + c \sum_{i=1}^n x_i^3$$

$$\frac{\partial h}{\partial c} = -2 \sum_{i=1}^n x_i^2 (y_i - a - bx_i - cx_i^2) = 0$$

$$\sum_{i=1}^n x_i^2 y_i - a \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i^3 - c \sum_{i=1}^n x_i^4 = 0$$

$$\sum_{i=1}^n x_i^2 y_i = a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i^3 + c \sum_{i=1}^n x_i^4$$

3. (4 puntos) Don Francisco tiene 8 clientes a los que les ha vendido mercancías a crédito y, de ellos, 1 están en mora con el pago prometido. Matías, teniendo en cuenta la información disponible, considera que puede modelar el porcentaje p de morosidad según una distribución $\mathcal{B}(2, 3)$. Para determinar los parámetros α y β , decide usar inferencia bayesiana. Con esto, pretende explicarle a Don Francisco, cómo será el comportamiento de pago de sus clientes a crédito. Determinen la distribución a posteriori del parámetro p de porcentaje de morosidad (α y β). Determinar su media y su varianza.

Sea p la probabilidad de que un cliente se encuentre en mora, con $0 \leq p \leq 1$. Aunque la consigna la llama “porcentaje”, técnicamente p es una probabilidad: el porcentaje correspondiente se obtiene como $100p\%$.

Tenemos 8 clientes, de los cuales 1 está en mora y los 7 restantes están al día con el pago.

Distribución a priori: Matías la modeló usando una distribución Beta(α, β) con parámetros previos $\alpha = 2$ y $\beta = 3$:

$$\pi(p) = \text{Beta}(2, 3) = \frac{1}{B(2, 3)} p^{2-1} (1-p)^{3-1} = \frac{1}{B(2, 3)} p (1-p)^2$$

donde $B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$ es la función Beta.

Verosimilitud: Modelamos el número total de clientes en mora X como una variable Binomial. Con $n = 8$ clientes independientes, cada uno en mora con probabilidad p , el número de morosos sigue $X \sim \text{Binomial}(n, p)$. Su función de probabilidad es:

$$f_{X|P=p}(x) = \binom{n}{x} p^x (1-p)^{n-x} = \binom{8}{1} p^1 (1-p)^7 = 8p(1-p)^7$$

ya que observamos $x = 1$ cliente moroso de un total de $n = 8$.

Distribución a posteriori: Usamos el teorema de Bayes para calcular la distribución a posteriori. Como la distribución Beta es conjugada de la distribución Binomial, esperamos obtener nuevamente una distribución Beta.

$$f_{P|X=x}(p) = \frac{f_{X|P=p}(x) \pi(p)}{\int_0^1 f_{X|P=u}(x) \pi(u) du}$$

Reemplazando la verosimilitud y la priori:

$$f_{P|X=x}(p) = \frac{\binom{8}{1} p (1-p)^7 \cdot \frac{1}{B(2, 3)} p (1-p)^2}{\int_0^1 \binom{8}{1} u (1-u)^7 \cdot \frac{1}{B(2, 3)} u (1-u)^2 du}$$

Las constantes $\binom{8}{1}$ y $\frac{1}{B(2,3)}$ no dependen de la variable de integración, por lo que salen de la integral y se cancelan con el numerador:

$$f_{P|X=x}(p) = \frac{p^2 (1-p)^9}{\int_0^1 u^2 (1-u)^9 du}$$

Reconocemos la integral del denominador como una función Beta:

$$\int_0^1 u^2 (1-u)^9 du = \int_0^1 u^{3-1} (1-u)^{10-1} du = B(3, 10)$$

Por lo tanto:

$$f_{P|X=x}(p) = \frac{1}{B(3, 10)} p^{3-1} (1-p)^{10-1}$$

que es exactamente la densidad de una distribución Beta($\alpha_{post}, \beta_{post}$).

$$\boxed{\alpha_{post} = 3 \quad \beta_{post} = 10}$$

es decir, $P | X \sim \text{Beta}(3, 10)$.

Para una distribución Beta(α, β), la media y la varianza son:

$$E[p] = \frac{\alpha}{\alpha + \beta} \quad \text{Var}(p) = \frac{\alpha \beta}{(\alpha + \beta)^2 (\alpha + \beta + 1)}$$

Aplicando con $\alpha = 3$ y $\beta = 10$:

$$E[p] = \frac{3}{13} \approx 0.2308$$

$$\text{Var}(p) = \frac{3 \cdot 10}{13^2 \cdot 14} = \frac{30}{2366} = \frac{15}{1183} \approx 0.01268$$

$$\boxed{\mu = \frac{3}{13} \quad \sigma^2 = \frac{15}{1183}}$$

Interpretación del comportamiento de pago:

Luego de combinar la información previa con los datos observados, la tasa esperada de morosidad es aproximadamente del 23.1% ($E[p] = 3/13$). Este valor queda entre dos referencias:

- la proporción observada en los datos: $\frac{1}{8} = 12.5\%$ (un cliente moroso de ocho)

- la media de la distribución previa Beta(2, 3): $\frac{2}{5} = 40\%$.

La posterior se ubica entre ambas porque la inferencia bayesiana pondera la creencia inicial (priori) con la evidencia (datos). Como la muestra es pequeña ($n = 8$), la priori todavía tiene peso y “tira” la estimación hacia arriba respecto del 12.5% observado. A medida que aumente el tamaño de la muestra, la influencia relativa de la priori disminuirá y la posterior quedará dominada por la información aportada por los datos.

La varianza posterior es $\text{Var}(p) \approx 0.01268$, y el desvío estándar posterior es $\sqrt{0.01268} \approx 0.113$, lo que refleja una dispersión considerable de la distribución posterior y, por lo tanto, incertidumbre sobre el valor real de p , coherente con el tamaño reducido de la muestra.

En términos prácticos para Don Francisco: la media posterior de la probabilidad de morosidad es aproximadamente 23.1%. Con solo ocho clientes, esta cifra no debe tomarse como una predicción exacta del número de morosos futuros, sino como una estimación que se irá afinando conforme observe el comportamiento de más clientes.

3) Solicite $\rightarrow$ more
 $\rightarrow$ bien
 p : probabilidad de morosidad
 $\pi(p) = p(z, 3) = \frac{1}{B(2, 3)} p^1 (1-p)^2$
 $f_{X|P=p}(x) = \binom{n}{x} p^x (1-p)^{n-x} = 8 p (1-p)^7$
 $\rightarrow$ porque nuestros "exits" en la more y los defaults son ind.
 Entonces:

$$f_{P|X=x}(p) = \frac{f_{X|P=p}(x) \pi(p)}{\int_0^1 f_{X|P=p}(x) \pi(p) dp}$$

$$= \frac{\binom{8}{x} p^x (1-p)^{8-x} \frac{1}{B(2, 3)} p^1 (1-p)^2}{\int_0^1 \binom{8}{x} p^x (1-p)^{8-x} \frac{1}{B(2, 3)} p^1 (1-p)^2 dp}$$

$$= \frac{p^2 (1-p)^9}{\int_0^1 p^2 (1-p)^9 dp}$$
 como $p(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$ } $\alpha=3$
 $\beta=10$
 Entonces:

$$f_{P|X=x}(p) = \frac{1}{B(3, 10)} p^{3-1} (1-p)^{10-1} = B(3, 10)$$

$\alpha=3$
 $\beta=10$

Wegs por definicion:
 $E(p) = \frac{\alpha}{\alpha+\beta} = \frac{3}{13} \approx 0,2308$

$$\text{Var}(p) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} = \frac{30}{13^2 \cdot 10} = \frac{30}{2366} \approx 0,01268$$

$\mu = \frac{3}{13}$

$\sigma^2 = \frac{30}{2366}$